



UNIVERSIDAD DE GRANADA

DETECCIÓN DE ANOMALÍAS CON EL
DATASET WAVEFORM

Minería de Datos: Aprendizaje No Supervisado
y Detección de Anomalías

Máster en Ciencia de Datos e Ingeniería de
Computadores

Ana Fuentes Rodríguez

1º semestre 2024/25

Índice

1. Objetivo	2
2. Conjunto de datos utilizado y selección de variables	2
3. Detección de outliers en una dimensión	2
3.1. Outliers IQR	2
3.2. Tests de hipótesis	10
3.3. Trabajando con varias columnas	12
4. Outliers multivariantes	18
4.1. Métodos estadísticos basados en la distancia de Mahalanobis . . .	19
4.2. Visualización de datos con un biplot	21
4.3. Métodos basados en distancias LOF	22
4.4. Métodos basados en Clustering	28
4.5. Análisis de los outliers multivariantes puros	34
5. Conclusiones	35
Referencias	37

Resumen

En este trabajo se ha analizado la presencia de valores anómalos para el conjunto de datos “Waveform”. En primer lugar, se ha hecho un preprocesamiento de los datos para poder trabajar con ellos. Seguidamente, se han estudiado las anomalías presentes en una única variable y se han comparado con el resto de variables por diferentes métodos, tanto gráficos como estadísticos. Por último, se han estudiado los valores anómalos multivariantes, también mediante métodos gráficos y estadísticos, además de estudiar los outliers que son multivariantes puros.

1. Objetivo

El objetivo principal de este proyecto ha sido el estudio de los outliers o valores anómalos en el conjunto de datos “Waveform” [1]. En concreto, se ha realizado un estudio de los outliers en una sola variable y, seguidamente, se han estudiado los valores anómalos que presentan una combinación anómala de dos o más variables, utilizando métodos visuales, estadísticos y cuantitativos no estadísticos.

2. Conjunto de datos utilizado y selección de variables

El conjunto de datos con el que se ha trabajado es el denominado “Waveform”, cuyos datos están caracterizados por 21 atributos (columnas), además de una variable que identifica cada instancia y otra que indica si en esa columna hay outliers (“yes” o “no”).

Este conjunto se compone de 3443 instancias (filas) que se han generado a partir de combinaciones de tres formas de onda, a las que se les ha añadido ruido para dar variabilidad. Las 21 primeras variables contienen valores numéricos, los que se han generado midiendo la amplitud de la onda final en un tiempo determinado.

Antes de realizar el estudio de anomalías, se ha tenido que modificar ligeramente este conjunto de datos. Una vez guardado la información en un data frame, se han eliminado las dos últimas columnas del mismo; la variable “outlier” por ser de tipo factor y no numérica (Tabla 1) y la segunda por no aportar información relevante para el análisis. Además, se ha comprobado que este dataset no contiene missing values (NAs), por lo que no hay que eliminar ninguna fila.

¿Es numérica?											
att1	att2	att3	att4	att5	att6	att7	att8	att9	att10	att11	att12
Sí	Sí	Sí	Sí	Sí	Sí	Sí	Sí	Sí	Sí	Sí	Sí
att13	att14	att15	att16	att17	att18	att19	att20	att21	id	outlier	
Sí	Sí	Sí	Sí	Sí	Sí	Sí	Sí	Sí	Sí	No	

Tabla 1: Resumen del tipo de dato que contiene cada variable para eliminar las variables que no sean numéricas (Sí: es numérica, No: es categórica).

Con este pequeño preprocesamiento del conjunto de datos, se ha procedido con el estudio de las anomalías presentes en él, tanto las que sólo aparecen en una sola variable y las que aparecen en más de una variable.







3. Detección de outliers en una dimensión









3.1. Outliers IQR

En primer lugar, se ha de comprobar que ninguna de las variables no siguen una distribución “rara”, es decir, si sus histogramas presentan picos múltiples o en forma de U, se deberían eliminar. Así pues, se han generado histogramas para estudiar la distribución de dichas variables, los que se han mostrado en la Figura 1. Además, se ha mostrado a continuación el código ejecutado para generar estos histogramas.

```

1 #Pintar histogramas de las variables
2 par(mfrow = c(2, 2)) #Si es m s grande da error
3
4 sapply(1:ncol(datos.num), function(i) {
5     hist(datos.num[[i]], main = "", xlab = names(datos.num)[i],
6         ylab = "Frecuencia", border = "black")
7 })
    
```








Figura 1: Histogramas de cada una de las variables numéricas del conjunto de datos “Waveform” con el objetivo de estudiar visualmente la distribución de cada variable.

Como se puede observar en estos histogramas, todas las variables presentan una distribución relativamente normal, es decir, todas aparentan seguir una distribución gaussiana; no presentan picos múltiples, ni tienen

forma de U ni siguen una distribución uniforme. De esta manera, se han mantenido todas estas variables en este estudio.

Dado que todas las variables siguen, aproximadamente, la misma distribución, se ha seleccionado, por ejemplo, la cuarta variable para estudiar los valores anómalos presentes en esta variable en concreto.

Obtención de los outliers IQR

En primera instancia, se han calculado los valores anómalos existentes al calcular las diferencias entre cuartiles. Para ello, se han generado las siguientes líneas de código:

```
1 #Outliers IQR
2 cuartil.primerio <- quantile(columna, 0.25)
3 cuartil.tercero <- quantile(columna, 0.75)
4 iqr <- IQR(columna)
5 extremo.superior.outlier.IQR <- cuartil.tercero + 1.5*iqr
6 extremo.inferior.outlier.IQR <- cuartil.primerio - 1.5*iqr
7 extremo.superior.outlier.IQR.extremo <- cuartil.tercero + 3*iqr
8 extremo.inferior.outlier.IQR.extremo <- cuartil.primerio - 3*iqr
9 son.outliers.IQR <- ((columna < extremo.inferior.outlier.IQR) | (columna >
    extremo.superior.outlier.IQR))
10 son.outliers.IQR.extremos <- ((columna < extremo.inferior.outlier.IQR.
    extremo) | (columna > extremo.superior.outlier.IQR.extremo))
```

En este código se han calculado los cuartiles primero y tercero para calcular la distancia entre ellos (IQR) y así calcular los outliers IQR y los outliers IQR extremos, los que superan por 1.5 o por 3 la distancia intercuartil (respectivamente) por encima o por debajo de los cuartiles 1 y 3. Después de calcular estos datos, se han obtenido, de manera booleana, qué valores se consideran outliers para la variable seleccionada.

Al ejecutar este código se han obtenido los resultados de la Tabla 2 donde se ha aportado información de los valores para el primer y tercer cuartil, la distancia intercuartil y el número total de outliers IQR y outliers IQR extremos para esta variable.

1 ^{er} cuartil	2 ^o cuartil	IQR	Total outliers	Total outliers extremos
0.3733	0.5746	0.2013	10	0

Tabla 2: Resultados de la ejecución del código para obtener el valor del primer cuartil, tercer cuartil la distancia intercuartil y el total de outliers IQR y outliers IQR extremos para la cuarta variable del dataset “Waveform” (“att4”).

Observando esta tabla se puede comprobar que esta variable presenta 10 outliers IQR pero ninguno es extremo (ninguno supera ni por encima ni por debajo tres veces la distancia intercuartil). A continuación, se ha estudiado más a fondo cuáles son estos valores anómalos y se han observado en gráficos para compararlos con el resto de valores.

Índices y valores de los outliers IQR

A continuación, se han obtenido los índices de las filas que contienen un outlier en la columna seleccionada, así como el valor correspondiente en la columna que se está estudiando. De esta manera, se ha implementado el código siguiente:

```
1 claves.outliers.IQR <- which(son.outliers.IQR)
2 claves.outliers.IQR.extremos <- which(son.outliers.IQR.extremos)
3 df.outliers.IQR <- datos.num[claves.outliers.IQR,]
4 df.outliers.IQR.extremos <- datos.num[claves.outliers.IQR.extremos,]
5 nombres.outliers.IQR <- row.names(df.outliers.IQR)
6 nombres.outliers.IQR.extremos <- row.names(df.outliers.IQR.extremos)
7 valores.outliers.IQR <- columna[claves.outliers.IQR]
```

```
valores.outliers.IQR.extremos <- columna[claves.outliers.IQR.extremos]
```

Estas variables aportan información acerca de en qué posición se encuentran los valores anómalos (las variables llamadas “claves”), dos data frames que contienen la información de los outliers de esta columna, añadiendo también los valores que toma la instancia con respecto al resto de atributos, los nombres de las instancias que presentan un valor anómalo en la cuarta columna y el valor que estos toman.

Desviación de los outliers con respecto a la media de la columna

Las variables de este conjunto de datos presentan unas distribuciones cercanas a una normal, por lo que se ha aplicado el método z-score para normalizar los datos de cada columna. De esta manera, se han obtenido los outliers que se han generado anteriormente en la columna 4 para comprobar si se pueden considerar o no como outliers.

Además, también es interesante comparar el valor que toma la instancia para la cuarta columna con respecto al resto de variables, con el fin de comprobar si para el resto de variables se considera también como outlier.

A continuación, se han mostrado las líneas de código que se han implementado para observar los outliers IQR normalizados y en la Tabla 3 los valores que toman.

```
valores.outliers.IQR.norm <- columna.norm[son.outliers.IQR]
datos.num.zscore.outliers.IQR <- datos.num.zscore[son.outliers.IQR, ]
```

36	273	1090	1331	1740	2347	2635	2667	3066	3143
2.786	3.556	2.744	2.886	2.737	2.979	-3.275	3.157	2.929	2.858

Tabla 3: Valores de los outliers IQR normalizados de la cuarta variable.

En una distribución normal $N(0,1)$, se puede considerar outlier no extremo a partir del valor ± 2.698 y como outlier extremo a partir de ± 4.69 , por lo que los valores que se han obtenido, efectivamente, se pueden considerar valores anómalos, pero no llegan a ser outliers extremos.

Por otro lado, comparando con el resto de columnas, la mayoría de los outliers obtenidos en la variable 4 no lo son para el resto de variables, lo que puede indicar que ha habido una desviación inesperada en la amplitud de la onda en ese punto debido al ruido añadido o debido a que la suma de las tres ondas que forman estas instancias pueden haber generado un pico o un valle inusual. No obstante, se han generado gráficos más adelante con el propósito de visualizar esto más claramente.

Gráficos y diagramas de cajas

En efecto, se han generado una serie de gráficos para entender mejor dónde se encuentran estos valores anómalos. En primer lugar, se han generado dos scatterplots (mostrados en las Figuras 2 y 3) que muestran, respectivamente, los outliers IQR normales y los outliers IQR extremos que aparecen en la cuarta variable. En segundo lugar, se han mostrado varios boxplots, para mostrar en qué lugar se encuentran los outliers con respecto a los cuartiles (Figuras 4, 5 y 6). En otro boxplot se han representado todas las variables y dónde se encuentran las instancias detectadas como outliers normales (como extremos no hay no se ha realizado ningún gráfico) en el resto de variables (Figura 7).

```
#Gráficos de dispersión
grafico1 <- plot_2_colores(columna.norm, claves.outliers.IQR, "Max_length_
  aspect_ratio", )
grafico2 <- plot_2_colores(columna.norm, claves.outliers.IQR.extremos, "Max
  _length_aspect_ratio", )

#Boxplots
boxplot1 <- diag_caja_outliers_IQR(datos.num, indice.columna)
boxplot2 <- diag_caja(datos.num, indice.columna, claves.outliers.IQR)
```

```

8 boxplot2.extremos <- diag_caja(datos.num, indice.columna, claves.outliers.
  IQR.extremos)
9 boxplot.junto <- diag_caja_juntos(datos.num, "Outliers en alguna columna",
  claves.outliers.IQR)

```




Figura 2: Gráfico de dispersión donde se han mostrado los valores que toman las instancias para la variable 4 y donde se han mostrado en color rojo los detectados como outliers IQR normales.




Figura 3: Gráfico de dispersión donde se han mostrado los valores que toman las instancias para la variable 4 y donde se han mostrado en color rojo los detectados como outliers IQR extremos (como no hay, no hay ningún punto rojo en el gráfico).




Figura 4: Gráfico donde se ha mostrado el lugar que ocupan los outliers IQR normales en el boxplot.





Figura 6: Gráfico donde se ha mostrado el nombre de las instancias detectadas como outliers extremos en el box-plot (no hay ningún outlier IQR extremo en la variable 4).



Por otro lado, la mayoría de las instancias excepto la “3066” son outliers IQR únicamente en la cuarta variable, lo que puede justificarse, como ya se ha explicado, con la adición de ruido sintético para dar variabilidad. El dato 3066 presenta también un valor anómalo en el atributo 5; además de que el resto (excepto

el 2635) de outliers de la variable 4 se encuentran por encima del tercer cuartil, lo que puede significar que, efectivamente, al combinar linealmente los tres tipos de ondas se ha generado un pico en el tiempo medido en la variable 4 y en la variable 5 este pico de amplitud desciende, haciendo que todos los valores sean más típicos (excepto para el dato 3066 que asciende, el pico máximo se encuentra en esa variable, en la columna 4 toma un valor más bajo).

3.2. Tests de hipótesis

Test de Grubbs

Posteriormente, se ha realizado el test de Grubbs para comprobar si el valor que más se aleja de la media de la cuarta variable se puede considerar outlier desde un punto de vista estadístico. Para ello, se ha establecido como hipótesis nula que dicho dato más alejado no es un outlier.

Con la función `grubbs.test` disponible en `outliers` se ha obtenido un p-value de 0.7163 para la instancia “273” (con un valor normalizado para la cuarta columna de 3.556). Como el p-value es superior a 0.05, el test no puede rechazar, por lo que este valor no se puede considerar como anómalo, estadísticamente hablando.

Finalmente, se ha comprobado que el valor del posible outlier es 1, que, efectivamente, es el valor que toma la instancia 273 (aunque no ha rechazado la hipótesis nula); también se ha calculado qué lugar ocupa en el data frame (es la misma que el nombre de la instancia, 273).

Comprobación de la hipótesis de Normalidad

Aunque el test no ha podido rechazar la hipótesis, se ha comprobado de igual modo si la distribución que sigue la columna seleccionada es normal o no.

Para ello, se ha eliminado de la columna el valor más alejado de la media y se ha estudiado el histograma, un gráfico QQ y se ha generado otro test de hipótesis. En la Figura 8 se ha reflejado el histograma de la columna modificada y una curva para estudiar visualmente si la distribución que sigue la variable es normal o no.




Figura 8: Gráfico donde se representa el histograma de la cuarta variable del dataset sin el dato más alejado de la media (el 273) y con la línea gaussiana para comprobar gráficamente si sigue una distribución normal o no.

En este primer gráfico no se ve del todo claro si la distribución de la variable se puede considerar normal. La curva no se ajusta de manera exacta al histograma, pero, visualmente, podría despreciarse en un principio.

Seguidamente, se ha representado el gráfico QQ (quantil-quantil) para esta columna, reflejándose en la Figura 9.




Figura 9: Gráfico QQ de la cuarta variable del dataset con el fin de comprobar la normalidad de esta variable.

En este segundo gráfico se ha podido observar que hay numerosos puntos, tanto al principio como al final del gráfico, que se alejan demasiado de la línea de tendencia, por lo que ya no sería tan adecuado considerar la distribución como normal.

Finalmente, y para aclarar esto, se ha realizado un test de Shapiro, cuya hipótesis nula es que la distribución subyacente de la variable estudiada es normal. Al ejecutar este test de hipótesis, se ha obtenido un p-value de $3.431 \cdot 10^{-13}$; este valor es notablemente inferior a 0.05, por lo que se puede rechazar con seguridad la hipótesis y se puede considerar que esta variable no presenta una distribución normal. Esto quiere decir que, al no seguir esta variable una distribución normal, no se puede conocer, mediante el test de Grubbs, si el valor extremo es un outlier o no desde el punto de vista estadístico, ya que este test de hipótesis asume que la distribución de la variable sí es normal.

Por otra parte, según el método IQR hay varios valores más considerados outliers, por lo que estos valores que no han sido eliminados también podrían modificar la distribución de esta variable; es decir, si se hubieran eliminado estos valores la distribución se desplazaría hacia la derecha y se parecería más a una normal (al menos desde el punto gráfico).

Construcción de una función propia

Con el propósito de resumir todo lo anterior, se ha implementado una función llamada `test_Grubbs`, cuyos resultados se han expuesto en la Tabla 4 y sus líneas de código se han mostrado a continuación:

```
1 test_Grubbs <- function(data.frame, indice.columna, alpha = 0.05){
2   #Seleccionar la columna
3   columna <- data.frame[,indice.columna]
4   #Para calcular cu n alejados est n los puntos de la media
5   desvios <- abs(columna - mean(columna, na.rm = TRUE))
6   clave.mas.alejado.media <- which.max(desvios)
7   valor.mas.alejado.media <- columna[clave.mas.alejado.media]
```

```

8  nombre.mas.alejado.media <- row.names(data.frame)[clave.mas.alejado.media]
9  grubbs.test <- grubbs.test(columna)
10 es.outlier <- grubbs.test$p.value < alpha
11 p.value <- min(grubbs.test$p.value * 2)
12 columna.sin.alejado <- columna[-clave.mas.alejado.media]
13 test.normalidad <- shapiro.test(columna.sin.alejado)
14 es.distrib.norm <- test.normalidad$p.value >= alpha
15 p.value.test.normalidad <- test.normalidad$p.value
16 listafinal <- list(
17   nombre.columna = colnames(data.frame)[indice.columna],
18   clave.mas.alejado.media = clave.mas.alejado.media,
19   valor.mas.alejado.media = valor.mas.alejado.media,
20   nombre.mas.alejado.media = nombre.mas.alejado.media,
21   es.outlier = es.outlier,
22   p.value = p.value,
23   p.value.test.normalidad = p.value.test.normalidad,
24   es.distrib.norm = es.distrib.norm
25 )
26
27 listafinal
28 }
29
30 test <- test_Grubbs(datos.num, indice.columna, ) #4a columna
31 test

```

nombre.columna	att4
clave.mas.alejado.media	273
valor.mas.alejado.media	1
nombre.mas.alejado.media	"273"
es.outlier	FALSE
p.value	1.283694
p.value.test.normalidad	$3.43139 \cdot 10^{-13}$
es.distrib.norm	FALSE

Tabla 4: Resultados al implementar la función `test_Grubbs` que resume el test de Grubbs y el test de Shapiro para saber si el dato más alejado de una variable se considera o no outlier y si esta variable sigue una distribución normal.

Comparando los métodos estadísticos utilizados con el método IQR, para este último método han salido 10 outliers, mientras que para los test de hipótesis no ha salido ninguno. Para el método IQR, la única restricción a tener en cuenta es que la distribución de la variable estudiada no sea demasiado “rara”, a diferencia del test de Grubbs, cuya restricción es que la distribución subyacente ha de ser una normal $N(0,1)$.

3.3. Trabajando con varias columnas

A continuación, se ha repetido todo el procedimiento previo pero, en esta ocasión, se han estudiado los posibles valores anómalos presentes para todas las columnas.

Outliers IQR

En primer lugar, se han generado unas líneas de código para conocer los outliers que aparecen en alguna columna y los que aparecen en más de una columna (mediante el método IQR). Posteriormente, se han im-

plementado unas líneas de código, mostradas a continuación, que revelan el valor de la instancia detectada como outlier para alguna variable. En la Tabla 5, además, se ha mostrado un pequeño ejemplo para entender esto mejor y en la Figura 10 se ha representado un boxplot con toda esta información.

```
1 valores.outliers.IQR.alguna.columna.norm <- datos.num.zscore[claves.
  outliers.IQR.en.alguna.columna, ]
2 valores.outliers.IQR.alguna.columna.norm
3
4 #Para graficar el boxplot
5 diagrama <- diag_caja_juntos(datos.num, "Outliers en alguna columna",
  claves.outliers.IQR.en.alguna.columna)
6 par(mfrow = c(2, 3))
7 diagrama
```

Instancia	att1	att2	att3	att4	att5	att6
131	-2.7693	0.7479	-0.2849	1.2123	0.1182	0.9245
293	3.2266	0.0299	0.9269	-1.5796	-1.2975	-0.3801
347	-2.8085	0.4645	0.5941	1.0200	1.5281	1.6214
362	-2.9165	-0.0362	-1.6588	0.7992	0.2147	1.8779
393	2.7752	-1.8783	0.4405	0.5784	-0.7794	0.1384

Tabla 5: Ejemplo de los valores que toman algunas instancias para algunas variables, donde han salido como valor anómalo en alguna variable (valores normalizados).




Figura 10: Boxplots donde aparecen todos los valores que son anómalos en alguna variable.

Para este conjunto de datos hay muchos valores detectados como anómalos (según el método IQR), por lo que el boxplot generado es bastante confuso. Sin embargo, ha sido útil para comprobar que la mayoría de

los valores detectados como outlier (los más alejados que se ven con mayor claridad) lo eran únicamente en una sola variable, signo de que se ha añadido ruido sintéticamente, o de unas pocas variables, indicio de que la combinación lineal de las ondas que componen las instancias genera una amplitud atípica; en una variable se detecta como outlier y en las columnas de alrededor o también es un valor anómalo o se encuentran por encima o por debajo del tercer o primer cuartil, según corresponda.


Es importante notar que para el cálculo de outliers para todas las columnas, en ninguna se ha obtenido valores anómalos extremos, por lo que carece de sentido mostrar el boxplot resultante (estaría vacío). Para obtener las claves para los outliers IQR extremos, basta con cambiar en la función `claves_outliers_IQR_en_alguna_columna` el parámetro de 1.5 por 3 para que se calculen los outliers extremos y no los normales.


```
1 # En Latex parte as la l nea porque no cabe m s
2 claves.outliers.IQR.extremos.en.alguna.columna <- claves_outliers_IQR_en_
  alguna_columna(datos.num, 3)
3 claves.outliers.IQR.extremos.en.alguna.columna
4 ## integer(0)
```


Test de hipótesis

Por otro lado, se ha hecho el test de Grubbs para todas las variables. En primer lugar, se han representado todos los histogramas de las variables con la curva por encima para estudiar su normalidad. Así pues, se ha reflejado en las siguientes líneas el código que se ha ejecutado y en la Figura 11 los histogramas obtenidos.

```
1 par(mfrow = c(2, 2))
2 sapply(seq_along(datos.num.sin.outlier), function(i) {
3   columna <- datos.num.sin.outlier[, i]
4   nombre_columna <- colnames(datos.num.sin.outlier)[i]
5   ajusteNormal <- fitdist(columna, "norm")
6   denscomp(ajusteNormal, xlab = nombre_columna, main = paste("Ajuste Normal
  para", nombre_columna))
7 })
```










Figura 11: Histogramas de las variables del conjunto de datos “Waveform” con la curva de normalidad con el fin de determinar si presentan una distribución normal o no.

Como se puede observar en estas imágenes, ninguna variable se aleja considerablemente de una distribución normal, por lo que se han mantenido todas las variables en el conjunto de estudio. De esta forma, la nueva variable `datos.num.var.norm` tendrá las mismas columnas y los mismos datos que la variable `datos.num`.

En segundo lugar, se ha realizado el test de Grubbs para todas las variables de este nuevo conjunto, obteniendo los resultados de la Tabla 6. La función implementada para aportar toda la información se ha mostrado posteriormente:

```
1 resultados.grubbs <- sapply(seq_along(datos.num.var.norm), function(i) {
2   columna <- datos.num.var.norm[, i]
3   nombre_columna <- colnames(datos.num.var.norm)[i]
4   resultado <- test_Grubbs(datos.num.var.norm, i, )
5   return(c(
6     nombre_columna = nombre_columna,
7     clave_mas_alejado_media = resultado$clave.mas.alejado.media,
8     valor_mas_alejado_media = resultado$valor.mas.alejado.media,
9     nombre_mas_alejado_media = resultado$nombre.mas.alejado.media,
10    es_outlier = resultado$es.outlier,
11    p_value = resultado$p.value,
12    es_distrib_norm = resultado$es.distrib.norm,
13    p_value_test_normalidad = resultado$p.value.test.normalidad
14  ))
15 })
16 resultados.grubbs
```

nombre_columna	clave_mas_alejado_media	valor_mas_alejado_media	nombre_mas_alejado_media	es_outlier	p_value	es_distrib_norm	p_value_test_normalidad
att1	3274	1	3274	FALSE	0.4089	TRUE	0.1117
att2	1153	1	1153	FALSE	2	TRUE	0.1356
att3	1613	0	1613	FALSE	0.1944	FALSE	0.0005
att4	273	1	273	FALSE	1.2837	FALSE	$3.4314 \cdot 10^{-13}$
att5	3066	1	3066	FALSE	2	FALSE	$3.4976 \cdot 10^{-25}$
att6	1341	1	1341	FALSE	2	FALSE	$1.6189 \cdot 10^{-21}$
att7	2911	1	2911	FALSE	2	FALSE	$1.4855 \cdot 10^{-17}$
att8	1185	0	1185	FALSE	1.314	FALSE	$9.9157 \cdot 10^{-10}$
att9	1928	0	1928	FALSE	0.3743	FALSE	$2.3005 \cdot 10^{-19}$
att10	164	0	164	FALSE	1.3123	FALSE	$3.4292 \cdot 10^{-8}$
att11	835	1	835	FALSE	2	FALSE	$5.9732 \cdot 10^{-5}$
att12	2482	0	2482	FALSE	1.5717	FALSE	$4.5358 \cdot 10^{-8}$
att13	3402	0	3402	FALSE	1.6617	FALSE	$4.3598 \cdot 10^{-20}$
att14	2911	0	2911	FALSE	2	FALSE	$5.168 \cdot 10^{-12}$
att15	683	1	683	FALSE	2	FALSE	$2.52 \cdot 10^{-18}$
att16	3129	1	3129	FALSE	2	FALSE	$1.5266 \cdot 10^{-20}$
att17	1533	1	1533	FALSE	1.9045	FALSE	$4.2907 \cdot 10^{-20}$
att18	1841	1	1841	FALSE	2	FALSE	4.395710^{-11}
att19	2014	1	2014	FALSE	0.2432	FALSE	$1.8535 \cdot 10^{-5}$
att20	154	1	154	FALSE	0.1553	TRUE	0.8597
att21	1825	1	1825	FALSE	0.1664	TRUE	0.8649

Tabla 6: Resultados tras realizar el test de Grubbs para todas las variables del conjunto estudiado (datos.num.var.norm).

Como se puede observar en esta tabla, la mayoría de las variables, según el test de Shapiro, no presentan una distribución normal, salvo las variables “att1”, “att2”, “att20” y “att21”. Sin embargo, en los histogramas generados se ha comprobado que ninguna sigue una distribución muy alejada de este tipo de distribución, sino que presentan una distribución gaussiana sesgada hacia alguno de los lados.

Por otro lado, ninguno de los outliers que se han detectado en el método IQR se consideran valores anómalos, ya que ninguno de los valores más alejados de la media para cada variable han sido considerados como tal. Todos los p-values han resultado ser superiores a 0.05, por lo que no se ha podido rechazar la hipótesis nula (el valor más alejado no es outlier).

Es conveniente tener en cuenta que los únicos valores que se pueden afirmar que no son outliers son los que se han obtenido para las dos primeras y dos últimas variables, ya que son las únicas que sí se han considerado distribuciones normales (el test de Grubbs presupone que la distribución que siguen los datos es una distribución normal). Para el resto de valores no se ha podido confirmar desde el punto de vista estadístico.

4. Outliers multivariantes

En este apartado se han estudiado los valores anómalos multivariantes (en más de una variable) aplicando técnicas estadísticas basadas en distancias y en clustering.

4.1. Métodos estadísticos basados en la distancia de Mahalanobis

El requisito necesario para poder aplicar las técnicas estadísticas es, análogamente al apartado anterior, que la distribución subyacente de los datos sea una normal multivariante.

Es importante tener en cuenta que en esta situación no se puede estudiar la normalidad con métodos gráficos, ya que cuando se tienen más de dos variables no se pueden representar; se debe hacer mediante un test estadístico. Si la distribución conjunta de las variables es una normal multivariante, la variable formada al calcular las distancias de Mahalanobis, sigue una distribución χ^2 .

Comprobación de la normalidad usando gráficos QQ

En primer lugar, se ha comprobado la normalidad multivariante usando los cuantiles. Para ello, se han calculado las distancias de Mahalanobis y se ha comprobado que el gráfico QQ no se desvía considerablemente de una χ^2 . Así pues, se ha obtenido el gráfico representado en la Figura 12.




Figura 12: Gráfico QQ para comprobar la normalidad multivariante con distancias de Mahalanobis.

Se ha podido comprobar en esta figura que, efectivamente, es adecuado considerar que la distribución subyacente es normal multivariante, puesto que el gráfico QQ no se aleja demasiado de la línea de referencia. De este modo, se ha seguido trabajando con el conjunto de datos `datos.num.var.norm`; posteriormente, se ha realizado un test de hipótesis más restrictivo para verificar de forma estadística si es una distribución normal multivariante o no.

Comprobación de la normalidad usando un test de hipótesis

Como se ha comentado previamente, se ha realizado un test de hipótesis para dar una respuesta más técnica y restrictiva sobre la normalidad multivariante del conjunto estudiado. De esta manera, la hipótesis nula es que los datos provienen una distribución subyacente es normal multivariante. En la Tabla 7 se han mostrado los resultados obtenidos de este test.

MVN	p-value
NO	0

Tabla 7: Resultados del test de hipótesis para comprobar si los datos siguen una distribución normal multivariante.

El test realizado rechaza la hipótesis nula ($p\text{-value} < 0.05$), por lo que no se puede considerar que los datos presenten una distribución normal multivariante. Como se ha explicado en el guión [2], para conjuntos de datos grandes es muy difícil que estos tests estadísticos no rechacen, por lo que es lógico haber obtenido estos resultados.

Detección de outliers mediante cuantiles

Seguidamente, se han obtenido las distancias de Mahalanobis que se han representado en la Figura 12. Si la distribución subyacente que siguen los datos es normal multivariante, la distribución que siguen las distancias de Mahalanobis es una χ^2 , por lo que se han establecido como outliers aquellos valores que han obtenido una distancia de Mahalanobis superior al cuantil 97.5.

De este modo, se han implementado un pequeño código para conocer qué valores son considerados como outliers, reflejando en la Tabla 8 los resultados obtenidos (el nombre de las filas es el número de la clave, por lo que se ha anotado solo el nombre ya que se han obtenido numerosos valores).

```

1 cuantil_0975 <- quantile(dist.mah.clas, 0.975)
2 claves.outliers.mah.clas <- which(dist.mah.clas > cuantil_0975)
3 claves.outliers.mah.clas
4 nombres_filas <- function(datos.num, claves.outliers) {
5   # Extraer los nombres de las filas correspondientes a los outliers
6   rownames(datos.num)[claves.outliers]
7 }
8 nombres_filas(datos.num.var.norm, claves.outliers.mah.clas)

```

Nombre de las filas detectadas como outlier												
31	39	71	109	132	135	154	164	177	196	232	253	293
471	496	577	645	647	654	660	665	668	685	717	727	890
933	984	1052	1066	1098	1106	1134	1142	1198	1268	1333	1431	1441
1497	1573	1602	1613	1689	1709	1719	1773	1818	1827	1841	1910	1966
2014	2025	2041	2172	2217	2229	2235	2239	2257	2363	2369	2373	2383
2396	2457	2471	2507	2545	2561	2586	2705	2731	2761	2787	2831	2863
2868	2944	3048	3132	3255	3279	3343	3358	3402				

Tabla 8: Nombre de las filas donde se han detectado un outlier según las distancias de Mahalanobis.

Con este código se han obtenido 87 instancias detectadas como anomalías. Comparando con la Figura 12, las primeras y últimas distancias de Mahalanobis se encuentran más alejadas de la línea de referencia (las de los extremos del gráfico), por lo que estas habrán sido outliers detectados por este test.

Es curioso observar que, no por haberse detectado una instancia como outlier para una variable, es detectado como outlier para múltiples variables. Aunque son diferentes métodos, para la variable 4 se ha detectado como outlier IQR el valor de la fila 273; mientras que para el método de distancias de Mahalanobis esta fila

no se ha detectado como outlier multivariante. Esto confirma la afirmación de que hay valores que pueden ser anómalos en una sola variable pero no en un caso multivariante.

Como nota interesante, existen otros métodos más modernos, eficaces y robustos que calculan la distancia de Mahalanobis como, por ejemplo, el método MCD (“Minimun Covariance Determinant”). Este método calcula estas distancias haciendo una estimación de la matriz de covarianzas y construyendo estadísticos. Con las siguientes líneas de código se han obtenido los mismos outliers que para el procedimiento anterior.

```
1 # Calcular el vector de distancias de Mahalanobis usando MCD
2 dist.mah.mcd <- Mahalanobis(datos.num.var.norm, method = "mcd")
3 cuantil_97_5_mcd <- quantile(dist.mah.mcd, 0.975)
4 claves.outliers.mah.mcd <- which(dist.mah.mcd > cuantil_97_5_mcd)
5 claves.outliers.mah.mcd
6 nombres_filas(datos.num.var.norm, claves.outliers.mah.mcd)
```

Test de hipótesis para detectar outliers

Por último en este apartado, se ha realizado un test de hipótesis partiendo de la idea de que la distribución que siguen los datos sí es una normal multivariante (el gráfico QQ ha dado buenos resultados visuales aunque el test haya rechazado que fuera una normal multivariante). De esta manera, se ha establecido como hipótesis nula de este test que el valor detectado como outlier realmente no lo es, por lo que si rechaza sí es realmente un outlier. Así pues, se ha generado un test individual y un test de intersección.

Con el método individual se han obtenido 162 outliers, mientras que con el test de intersección no se ha obtenido ninguno. El test de intersección es más conservador que el individual, por lo que es lógico que no se haya obtenido ningún valor anómalo. Por otro lado, para todos los valores que se han obtenido del test individual sólo se tiene garantía de ser outlier el primero que se ha obtenido (por tener la mayor distancia de Mahalanobis), siendo este el dato “10”.

4.2. Visualización de datos con un biplot

Posteriormente, se han generado una serie de gráficos de tipo biplot para poder estudiar los outliers obtenidos por el método IQR y poder también estudiar las correlaciones entre variables, aunque es importante recordar que en estos gráficos, al ser en 2D, se pierde algo de información. Por ello, se han generado y mostrado en la Figura 13 el biplot para los outliers IQR normales presentes en alguna columna del conjunto datos.num (no hay ningún outlier IQR extremo, por lo que el biplot generado sería igual que el mostrado pero sólo puntos negros, carece de sentido representarlo).




Figura 13: Biplot del conjunto de datos `datos.num` para comprender los outliers detectados y las correlaciones entre las variables del conjunto.

Hay numerosos datos que se han detectado como anómalos en alguna columna (en concreto, 259 valores). De esta forma, el biplot que se ha generado es bastante confuso. Se ha intentado crear un biplot eliminando aleatoriamente un porcentaje de los datos pero se perdía demasiada información y se deformaba mucho el gráfico, por lo que se ha dejado el biplot original.

De igual modo, se puede distinguir que la mayoría de los valores detectados como outliers se han encontrado más alejados del centro y en dirección de una única variable (es decir, que no se encuentran entre varias “flechas” que indican las variables), lo que indica que son univariantes.

Es curioso observar cómo hay variables que no tienen correlación entre sí (con la distribución de los puntos en el gráfico y en el centro se puede distinguir hacia qué dirección van las flechas), mientras que otras parecen tener una correlación inversa, lo que tiene sentido, ya que como las variables miden la amplitud en el tiempo, mientras unas tienen un valor más alto otras tienen un valor más bajo.

4.3. Métodos basados en distancias LOF

Este método de distancias (basado en la distancia euclídea) no aporta información de cuán lejos están los valores del resto de datos, aunque no nos aportan una garantía estadística.

Para que no tenga más peso unas variables que otras, se han normalizado los datos mediante z-score (conjunto `datos.num.zscore`).

Por otro lado, para ejecutar el método LOF, se ha establecido en primera instancia el número de vecinos a 5. La función empleada da información de hasta qué punto un valor es un outlier; si se ordena el vector obtenido y se grafica, obteniendo el gráfico de la Figura 14. Además, se ha reflejado en la Figura 15 un aumento del extremo izquierdo de este gráfico para observar con mayor claridad los scores de cada valor.

```
1 indices.ordenados <- order(lof.scores,decreasing=TRUE)
2 lof.scores.ordenados <- lof.scores[indices.ordenados]
3 plot(lof.scores.ordenados, col = "black")
```




Figura 14: Gráfico donde se representa el vector de distancias ordenado generado por el método LOF.




Figura 15: Aumento del intervalo [0,100] del gráfico de la Figura 14 para observar mejor la posición y separación de los puntos.

Como se puede observar, hay cuatro puntos más alejados del resto, por lo que se selecciona el número de outliers a 4. Con este dato, se han implementado las siguientes líneas de código y se han mostrado los resultados en la Tabla 9.

```
1 num.outliers <- 4
2 claves.outliers.lof <- indices.ordenados[1:num.outliers]
3 nombres.outliers <- nombres_filas(datos.num.zscore, claves.outliers.lof)
```

Nombres de los outliers LOF			
2239	1441	2457	685

Tabla 9: Nombres de los outliers seleccionados con el método LOF (el nombre de estos outliers es el mismo número).


Tras esto, se han estudiado los valores de estos outliers normalizados para cada variable. Para los datos “2239”, “1441” y “685” presentan valores anómalos en una sola variable y es interesante observar que los tres también presentan un valor anómalo en la última variable “att21”. Para el dato “2457” sí se han presentado valores anómalos en más variables, sin embargo, no para la variable “att21”.













Esta diferencia entre los datos detectados como outliers es interesante, puesto que ayuda a comprender las inhomogeneidades de las anomalías en el conjunto de datos, lo que puede ser crucial a la hora de interpretar los resultados obtenidos.

Por un lado, que tres de cuatro datos interpretados como outliers tengan un valor anómalo en una única variable (además de la última) puede indicar que alguna de las ondas con las que se ha creado el conjunto es más susceptible al ruido en variables específicas.

Por otro lado, del dato que presenta valores anómalos en varias variables se puede inferir que es una anomalía global.

Ahora, se han generado interacciones 2 a 2 variables con el dato más alejado (el “2239”). Puesto que son 21 variables, se generan muchos gráficos y al generarlos de manera global no se puede ver nada en una sola imagen, por lo que se han creado varios gráficos en los que se representan todas las interacciones. Es un proceso engorroso y se repiten gráficos e interacciones, pero así ha sido posible mostrar con mayor claridad las interacciones entre todas las variables. Todo esto se ha mostrado en la Figura 16.








Figura 16: Gráficos de dispersión donde se muestran las interacciones 2 a 2 entre todas las variables.

Se puede observar cómo hay numerosas variables que presentan una dependencia directamente proporcional (cuando aumenta una aumenta la otra) como ocurre con las variables “att7” y la “att8” (en el biplot se ven también variables cuyas flechas siguen la misma dirección); otras que presentan una dependencia inversamente proporcional (cuando aumenta una disminuye la otra y viceversa), como ocurre con las variables “att9” y “att15”, mientras que en otras el gráfico de dispersión es una nube en la que no se ve ninguna dependencia (como se ha dicho en el biplot, no tienen correlación).

En la Figura 17 se ha reflejado el biplot donde se ha resaltado el valor detectado como outlier más alejado según el método LOF.




Figura 17: Biplot donde se muestra el mayor outlier según el método LOF.

De nuevo, el biplot obtenido no aporta demasiada información (38.4 % por una parte y 3.6 % por otra). No se ha podido extraer ninguna información relevante de este gráfico, solo que estos outliers no se encuentran en los extremos del gráfico.

4.4. Métodos basados en Clustering

En este apartado se ha estudiado otro método mediante distancias, pero en esta ocasión se ha calculado la distancia entre los puntos y un centroide (de cada cluster). De esta manera, se ha trabajado con el método k-means, por un lado, y el método k-medoides, por otro.

Clustering usando k-means

En un primer momento, se ha establecido como 5 el número de outliers y como 3 el número de clusters. Estableciendo la semilla, se ha implementado el modelo k-means y se han obtenido los resultados de la Tabla 10 y Tabla 11.

```
1 modelo.kmeans <- kmeans(datos.num.zscore, centers = num.clusters)
2 asignaciones.clustering.kmeans <- modelo.kmeans$cluster
3 centroides.normalizados <- modelo.kmeans$centers
4 head(asignaciones.clustering.kmeans)
5 centroides.normalizados
```

Asignación clustering k-means						
1	2	3	4	5	6	...
3	3	3	2	3	3	...

Tabla 10: Resultados de la asignación para el método de clustering k-means.

Centroides normalizados						
	att1	att2	att3	att4	att5	att6
1	-0.0071	-0.1709	-0.2691	-0.3683	-0.4091	-0.2638
2	0.0207	-0.2332	-0.3836	-0.498	-0.5664	-0.778
3	-0.012	0.4552	0.7336	0.9763	1.0981	1.129

Tabla 11: Centroides normalizados para el método de clustering k-means.

También se han calculado los centroides desnormalizados para obtener los valores originales. Un ejemplo de estos se han mostrado en la Tabla 12.

Centroides normalizados						
	att1	att2	att3	att4	att5	att6
1	0.4303	0.4544	0.4354	0.4967	0.4895	0.4104
2	0.4986	0.4094	0.4897	0.4145	0.4078	0.3236
3	0.5471	0.5427	0.6694	0.7209	0.643	0.6363

Tabla 12: Centroides para el método k-means sin normalizar.

Seguidamente, se han calculado los outliers como aquellos que más se alejan a su centroide. Para ello, se ha generado la siguiente función:

```

1 top_clustering_outliers <- function(datos.normalizados,
2                                     asignaciones.clustering,
3                                     datos.centroides.normalizados,
4                                     num.outliers) {
5   distancias <- distancias_a_centroides(datos.normalizados,
6                                           asignaciones.clustering,
7                                           datos.centroides.normalizados)
8   indices_ordenados <- order(distancias, decreasing = TRUE)
9   claves <- indices_ordenados[seq_len(num.outliers)]
10  list(distancias = distancias[claves], claves = claves)
11 }
12 outliers <- top_clustering_outliers(datos.num.zscore,
13                                     asignaciones.clustering.kmeans,
14                                     centroides.normalizados,
15                                     num.outliers = nrow(datos.num.zscore))
16 plot(outliers$distancias, col = "black")

```

Ejecutando este código se ha obtenido el gráfico de la Figura 18 con el que se puede determinar el número de outliers, de manera análoga a como se ha hecho con el gráfico obtenido con el método LOF (Figura 14). Del mismo modo, se ha graficado un menor intervalo de este gráfico para observar mejor los valores anómalos (Figura 19).




Figura 18: Gráfico para la detección de outliers mediante el método de clustering k-means.




Figura 19: Gráfico para los outliers con el método k-means en el intervalo [0,100].

Se pueden observar 5 valores posiblemente anómalos por encima, pero se han seleccionado 4 para poder comparar con el método LOF, como se indica en el guion. Se han obtenido los resultados de la Tabla 13.

Nombres de los outliers k-means			
73	2239	984	1827

Tabla 13: Nombres de las instancias detectadas como anomalías para el método k-means.

Como se puede comprobar, sólo un valor coincide con los que se han obtenido para el método LOF (el 2239). Este valor es el que más alejado se encuentra del resto en el método LOF, por lo que es lógico que se haya obtenido también para este método.

De nuevo, se ha realizado un biplot con los outliers para este método. Este se ha reflejado en la Figura 20. Además, en la Figura 21 se ha representado un boxplot donde aparecen estos valores anómalos para estudiar en qué lugar se encuentran en cada variable.




Figura 20: Biplot donde se muestran los outliers obtenidos con el método de clustering k-means.




Figura 21: Boxplot donde se muestran los outliers detectados en el método de clustering k-means.

De nuevo, el biplot generado es un poco confuso, pero da información bastante relevante. Por una parte, se puede comprobar que, como es lógico, los valores detectados como anómalos se han encontrado en los extremos de cada cluster. Por otra parte, es interesante comprobar también que dos de los outliers (el “2239” y el “984”) se han encontrado entre dos clusters, lo que puede indicar que presentan un valor anómalo en una variable.

El boxplot generado revela también mucha información. Para los datos “2239”, “984” y “1827”, se ha obtenido que son outliers en una única variable, con lo que al estudiar las anomalías multivariantes han resultado ser también anómalos. No obstante, el valor que más alejado que ha resultado al hacer el clustering (el “73”) no tiene ningún valor anómalo en ninguna variable, pero sí ha resultado ser un valor anómalo multivariante con este método y estas condiciones (3 centroides), lo que demuestra que una cosa no implica la otra.

Clustering usando k-medoides

A continuación, se ha estudiado la presencia de anomalías mediante otro método de clustering, el método k-medoides. De nuevo, se ha establecido una semilla para que se obtenga lo mismo en cada ejecución y se ha calculado la matriz de distancias. Posteriormente, se han obtenido los nombres de los medoides (estos son “3309”, “2957” y “2514”) y también se ha ejecutado el código presente en el guión para conocer los valores de los medoides en todas las variables.

Tras esto, se ha implementado una función (mostrada posteriormente) que muestra los outliers según el número que se haya establecido (tanto las claves como los nombres de estos datos). Además, se ha representado también el biplot de este modelo en la Figura 22. También se han reflejado los nombres de los outliers y su distancia a sus respectivos centroides en la Tabla 14.




Figura 22: Biplot para los outliers detectados para el método de clustering k-medoides.

```

1 outliers.pam <- top_clustering_outliers(datos.num.zscore,
2                                         asignaciones.clustering.pam,
3                                         medoides.normalizados, num.outliers
4                                         )
5 claves.outliers.pam <- outliers.pam$claves
6 nombres.outliers.pam <- rownames(datos.num)[claves.outliers.pam]
7 claves.outliers.pam
8 nombres.outliers.pam
9 outliers.pam$distancias
10 biplot_outliers_clustering(datos.num,
11                             titulo = "Outliers_pam",
12                             asignaciones.clustering = asignaciones.
13                             clustering.pam,
14                             claves.outliers = claves.outliers.pam)

```

Nombres de los outliers k-medoides			
1441	1827	2761	954
6.0347	5.9186	5.8497	5.8323

Tabla 14: Nombres de los 4 datos detectados como outliers y sus distancias a sus centroides para el método mmedoides.

Como ya ha ocurrido en los demás biplots, se ha obtenido un gráfico que no aporta mucha información,

pero, según donde se han obtenido los outliers, se ha podido inferir que se han obtenido estos datos porque presentan un valor anómalo en alguna columna y no porque su combinación haya resultado ser anómala (como ha ocurrido con el dato 73 para el método k-means). Con este método también se ha obtenido como valor anómalo el 1827, al igual que ocurría con el método k-means.

4.5. Análisis de los outliers multivariantes puros

Para finalizar este trabajo, se han estudiado los outliers puros. Estos se definen de modo general como aquellos datos que presentan valores anómalos en más de una variable (no son outliers univariantes, sino multivariantes). Un ejemplo válido es el dato “73”, detectado mediante k-means, el cual no presenta valores extremos en ninguna variable pero su combinación sí ha resultado ser anómala.

De esta forma, se han estudiado los outliers multivariantes puros eligiendo aquellos que han sido detectados como outliers con el método LOF pero no con el método IQR. De esta manera, se ha generado el código posterior:

```

1 claves.outliers.lof.no.IQR <- setdiff(claves.outliers.lof, claves.outliers.
  IQR.en.alguna.columna)
2 nombres.outliers.lof.no.IQR <- nombres_filas(datos.num, claves.outliers.lof.
  no.IQR)
3 ejemplo <- biplot_2_colores(datos.num, claves.outliers.lof.no.IQR,
4                               titulo = "Outliers LOF (excluidos los que son
5                               IQR)")
6 datos.num.zscore[claves.outliers.lof.no.IQR, ]

```

Al ejecutar este código se ha obtenido como outliers puros el “1441” (detectado también con el método k-medoides) y “2457”. Sólo se han obtenido estos dos valores debido a que sólo se han elegido 4 outliers con el método LOF. Si se observa más de cerca el gráfico de la Figura 15, se pueden considerar en total 12 valores más separados, dando un pequeño salto hasta el siguiente. Por tanto, se han seleccionado estos 12 y, ejecutando de nuevo el código anterior, se han obtenido siete outliers puros, mostrados en la Tabla 15.

Nombres de los outliers puros						
1441	2457	43	3343	232	2868	665

Tabla 15: Valores detectados como outliers multivariantes puros (con el método LOF).

De nuevo, se han graficado estos outliers en un biplot de dos colores para mostrar dónde se encuentran estos siete outliers. En la Figura 23 se ha reflejado este gráfico.




Figura 23: Biplot de los datos detectados como outliers multivariantes puros.

Este gráfico no da apenas información, debido a que no se ven dónde se encuentran la mayoría de los puntos. A la derecha del biplot, se pueden observar los datos “665”, “2868” y “2457”. Estos se encuentran al “final” de la nube de puntos, pero no son los valores más externos que hay en el biplot.

Al examinar los valores normalizados que toman estos valores para cada variable, se ha podido observar que, efectivamente, se han obtenido valores anómalos en más de una variable. Sin embargo, no se ha observado ningún patrón aparente, por lo que se ha podido inferir que esto ha sido consecuencia del ruido gaussiano añadido a los datos.

5. Conclusiones

Tras realizarse todo este análisis de datos y de detección de las anomalías presentes en el conjunto de datos “Waveform”, se ha podido concluir que hay numerosos datos que presentan un valor anómalo en una única variable, cuya causa puede deberse a que, con el objetivo de dar variabilidad al conjunto, se ha añadido ruido sintético de manera gaussiana. Esto se ha podido comprobar en las instancias 1740 y 2635, que sólo presentan valores anómalos en la cuarta variable, signo de que, posiblemente, al medir la amplitud en ese instante se le ha añadido ruido.

Por otro lado, se han obtenido también otras instancias que presentan valores anómalos en más de una variable. Por una parte, se han obtenido instancias que presentan anomalías en variables contiguas, como es el caso del dato 3066, lo que puede ser un indicio de que la combinación de los tres tipos de ondas con los que se han generado los datos ha creado una amplitud anómala (para confirmar esto, habría que realizar una matriz de correlación para confirmar que las variables contiguas están realmente relacionadas entre sí). Por otra parte, hay instancias que presentan anomalías en variables separadas, como los datos 1441 y 2457.

Se ha concluido, además, que es crucial que las distribuciones que siguen los datos sean normales a la hora de utilizar métodos estadísticos, ya que, métodos como el test de Grubbs parten de la premisa de que sí son distribuciones normales y, si no lo son, el resultado que aportan puede verse afectados. Para los métodos gráficos, esta consideración no es tan estricta.

Finalmente, también se ha comprobado cómo hay valores anómalos multivariantes que resultan de datos que no son anómalos en cada una de las variables. Como el caso del dato 73, no tiene valores extremos en ninguna de las variables, pero al estudiarlo de manera global, se ha obtenido que sí es un outlier multivariante. Para otros datos, no obstante, sí se ha obtenido que por ser anómalo en una variable también lo es de manera global.

Es importante, antes de terminar, que para este conjunto de datos no han sido de mucha ayuda los biplots generados, ya que hay una gran cantidad de datos y se han generado gráficos muy caóticos y nada claros. Se ha intentado reducir el número de datos representados, pero se deformaban los biplots y aportaban menos información aún.

Referencias

- [1] Ludwig Maximilian University of Munich, “Dami outlier detection datasets,” n.d. <https://www.dbs.ifi.lmu.de/research/outlier-evaluation/DAMI/>.
- [2] J. C. Cubero, “Guion de prácticas de la parte de detección de anomalías del curso aprendizaje no supervisado.” <https://ccia.ugr.es/~carlos/Master/Outliers.html>.